ForceCRM
Empowering Sales | Driving Results

Τεχνικό Brief

Profile Analysis Ελληνικών Επιχειρήσεων με Local AI

Ποιος θα είναι ο επόμενος πελάτης;

ForceCRM Challenge · Hackathon ΕΚΠΑ · Νοέμβριος 2026

1. Στόχος

Οι ομάδες αναπτύσσουν μια web εφαρμογή Profile Analysis για ελληνικές επιχειρήσεις εστίασης, σε όποια τεχνολογία θέλουν. Ο χρήστης ανεβάζει το πελατολόγιο μιας B2B εταιρείας σε Excel. Η εφαρμογή εντοπίζει τα Ideal Customer Profiles, τα περιγράφει στα ελληνικά και προτείνει νέες επιχειρήσεις που τους μοιάζουν. Όλη η εκτέλεση του AI γίνεται τοπικά σε laptop, με ευρωπαϊκά ή open-source μοντέλα.

2. Βασικοί όροι

Όρος	Σημασία
Πελατολόγιο	Excel με τους πελάτες μιας εταιρείας: ΑΦΜ και τζίρος που φέρνει ο κάθε πελάτης.
Universe	Όλες οι επιχειρήσεις του dataset, από τις οποίες προτείνονται νέοι πελάτες.
Ideal Customer Profile (ICP)	Ένας «τύπος» πελάτη: ομάδα πελατών με κοινά, μετρήσιμα χαρακτηριστικά.
Lookalike	Επιχείρηση του universe που δεν είναι πελάτης αλλά μοιάζει με ένα ICP.

3. Δεδομένα

Τα δεδομένα δίνονται σε τρία αρχεία CSV (UTF-8, διαχωριστικό ";", δεκαδικά με κόμμα, οι κενές τιμές εμφανίζονται ως NULL) και ένα Excel. Περιλαμβάνουν όλες τις ενεργές επιχειρήσεις με κύριο ΚΑΔ 56 (εστίαση) που ιδρύθηκαν από το 2020 έως το 2024: 24.424 εγγραφές, το 96% με στίγμα GPS.

3.1 vwHackCompany.csv — επιχειρήσεις

Πεδίο	Περιγραφή
company_id	Μοναδικό αναγνωριστικό εγγραφής. Κλειδί σύνδεσης με το vwHackCompanyActivity
vat	ΑΦΜ. Κλειδί σύνδεσης με το πελατολόγιο
company_name_el	Διακριτικός τίτλος ή, αν δεν υπάρχει, επωνυμία. Στις ατομικές χωρίς διακριτικό τίτλο: «Επιχείρηση Εστίασης»
legal_type	Νομική μορφή (ΑΤΟΜΙΚΗ, ΕΕ, ΙΚΕ, ΟΕ, ΑΕ, ΕΠΕ κ.λπ.)
is_branch	1 αν η εγγραφή είναι υποκατάστημα
street, street_number, zip_code, city	Διεύθυνση

Πεδίο	Περιγραφή
municipality_name, prefecture_name	Δήμος και Νομός
incorporation_date	Ημερομηνία ίδρυσης ή, για υποκατάστημα, έναρξης λειτουργίας
latitude, longitude	Στίγμα GPS

Υποκαταστήματα: ένα ΑΦΜ μπορεί να αντιστοιχεί σε περισσότερες από μία εγγραφές (έδρα και υποκαταστήματα), δηλαδή σε περισσότερα από ένα μαγαζιά. Κάθε μαγαζί είναι ξεχωριστή εγγραφή με δικό του company_id, διεύθυνση και στίγμα.

3.2 vwHackCompanyActivity.csv — δραστηριότητες ανά επιχείρηση

Πεδίο	Περιγραφή
company_id	Η επιχείρηση
activity_id	Κωδικός ΚΑΔ 8 ψηφίων (ΚΑΔ 2025 / NACE 2.1), χωρίς τελείες
activity_type	Κύρια, Δευτερεύουσα ή Βοηθητική
date_from	Ημερομηνία έναρξης της δραστηριότητας

3.3 vwHackActivities.csv — περιγραφές ΚΑΔ

Πεδίο	Περιγραφή
activity_id	Κωδικός ΚΑΔ 8 ψηφίων
description	Περιγραφή του κωδικού στα ελληνικά

3.4 Πελατολόγιο (Excel)

Ένα κοινό Excel για όλες τις ομάδες, με 300 πελάτες: ΑΦΜ και τζίρος ανά πελάτη. Ο τζίρος είναι ενδεικτικός. Κάθε ΑΦΜ του πελατολογίου αντιστοιχεί σε μία εγγραφή του vwHackCompany. Ένα μέρος των πελατών έχει αφαιρεθεί από την ForceCRM και χρησιμοποιείται στην αξιολόγηση (ενότητα 8).

Προσοχή: οι ΚΑΔ είναι δηλωτικοί. Πολλές επιχειρήσεις δηλώνουν δευτερεύοντες κωδικούς που δεν αντιστοιχούν σε πραγματική δραστηριότητα. Η λύση σας πρέπει να αντιμετωπίζει αυτόν τον θόρυβο.

3.5 Πηγές και άδειες

- **Στοιχεία επιχειρήσεων:** ΓΕΜΗ Open Data.
- **Στίγματα GPS:** γεωκωδικοποίηση με δεδομένα © OpenStreetMap contributors, διαθέσιμα με άδεια Open Database License (ODbL).
- Τα δεδομένα δίνονται αποκλειστικά για τον διαγωνισμό. Κάθε παρουσίαση ή δημοσίευση των αποτελεσμάτων αναφέρει τις παραπάνω πηγές.

4. Απαιτήσεις συστήματος

A1. **Αναπαράσταση επιχείρησης.** Συνδυάστε δραστηριότητα, γεωγραφία, νομική μορφή και ηλικία της επιχείρησης. Δώστε διαφορετικό βάρος σε κύρια και δευτερεύουσα δραστηριότητα. Αξιοποιήστε το σημασιολογικό περιεχόμενο των περιγραφών ΚΑΔ μέσω embeddings, όχι μόνο τους κωδικούς.

A2. **Ανακάλυψη ICP.** Το σύστημα βρίσκει από 1 έως 6 profiles και μπορεί να απαντήσει «ένα ICP» όταν το πελατολόγιο είναι ομοιογενές. Ο τρόπος που αξιοποιείται ο τζίρος (στάθμιση, επιλογή πελατών υψηλής αξίας ή άλλος) τεκμηριώνεται.

A3. **Συνέπεια σχηματισμού και ανάθεσης.** Η ίδια λογική και μετρική χρησιμοποιείται για τον σχηματισμό των profiles και για την ανάθεση μιας επιχείρησης σε profile. Κάθε ανάθεση έχει score εμπιστοσύνης και προβλέπεται η έκβαση «δεν ταιριάζει σε κανένα profile». Επιχειρήσεις με πολλούς ΚΑΔ δεν πρέπει να αδικούνται από τη μετρική.

A4. **Τεκμηρίωση profile.** Τα χαρακτηριστικά που ορίζουν ένα profile υπερεκπροσωπούνται με στατιστικά ελεγμένο τρόπο: έλεγχος σημαντικότητας (Fisher exact ή υπεργεωμετρικό, με διόρθωση πολλαπλών ελέγχων) ή shrinkage. Σπάνια χαρακτηριστικά δεν περνούν από τύχη.

A5. **Σταθερότητα.** Μετρήστε αν τα profiles επιβιώνουν σε επαναδειγματοληψία (bootstrap) ή σε μικρές αλλαγές παραμέτρων, π.χ. με Adjusted Rand Index. Αναφέρετε σταθερότητα ανά profile.

A6. **Περιγραφή με τοπικό LLM.** Το LLM γράφει την περιγραφή κάθε profile στα ελληνικά, μόνο από τα δεδομένα του profile: κάθε ισχυρισμός αντιστοιχεί σε μετρήσιμο στοιχείο. Η περιγραφή σημαίνεται ως κείμενο που παρήχθη από AI, εμφανίζει την ποιότητα και την εμπιστοσύνη του profile και είναι αναπαραγώγιμη (σταθερές παράμετροι παραγωγής).

A7. **Lookalike.** Για κάθε profile, το σύστημα κατατάσσει επιχειρήσεις του universe που δεν είναι ήδη πελάτες, με score και σύντομη αιτιολόγηση.

A8. **Web εφαρμογή.** Τρέχει σε localhost. Ο χρήστης ανεβάζει το Excel, βλέπει τα profiles με την περιγραφή και τα στοιχεία τους, και τις προτάσεις lookalike. Τα αποτελέσματα εξάγονται στα αρχεία της ενότητας 10.

5. Μοντέλα

Υπόθεση υλικού: laptop με 16 GB RAM, CPU ή consumer GPU. Πρακτικά αυτό σημαίνει LLM 3–9B παραμέτρων σε 4-bit quantization (Ollama ή llama.cpp) και embedding μοντέλα έως περίπου 600M παραμέτρους (sentence-transformers).

5.1 Ενδεικτικά LLM

Μοντέλο	Προέλευση	Άδεια	Σημείωση
EuroLLM-9B-Instruct	ΕΕ (EU-funded)	Apache 2.0	35 γλώσσες, με ελληνικά
Salamandra-7B-Instruct	Ισπανία (BSC)	Apache 2.0	Ευρωπαϊκές γλώσσες
Apertus-8B-Instruct	Ελβετία	Apache 2.0	Δημοσιευμένα δεδομένα εκπαίδευσης
Ministral-3-3B-Instruct	Γαλλία (Mistral AI)	Apache 2.0	Μικρό και γρήγορο
Llama-Krikri-8B-Instruct	Ελλάδα (ΙΛΣΠ / Αθηνά)	Llama 3.1 License	Εξειδικευμένο στα ελληνικά
Ministral-8B-Instruct-2410	Γαλλία (Mistral AI)	Mistral Research License	Όχι για εμπορική χρήση
Qwen3 (4B / 8B)	Κίνα (Alibaba)	Apache 2.0	Μη ευρωπαϊκό
Gemma 3 (4B / 12B)	ΗΠΑ (Google)	Gemma Terms	Μη ευρωπαϊκό

5.2 Ενδεικτικά embedding μοντέλα

Μοντέλο	Προέλευση	Άδεια	Σημείωση
jina-embeddings-v5-text-nano	Γερμανία (Jina AI)	Επαληθεύστε	Βάση EuroBERT, adapter για clustering. Επαληθεύστε κάλυψη ελληνικών
granite-embedding multilingual r2 (97M / 311M)	ΗΠΑ (IBM)	Apache 2.0	Πολύ ελαφρύ
Qwen3-Embedding-0.6B	Κίνα (Alibaba)	Apache 2.0	Πολυγλωσσικό
BGE-M3	Κίνα (BAAI)	MIT	Dense και sparse αναπαραστάσεις
multilingual-e5 (base / large)	ΗΠΑ (Microsoft)	MIT	Καθιερωμένο baseline
EmbeddingGemma-300M	ΗΠΑ (Google)	Gemma Terms	Μικρό μέγεθος

5.3 Αιτιολόγηση επιλογής

Η λίστα είναι ενδεικτική. Οποιοδήποτε άλλο μοντέλο γίνεται δεκτό, αρκεί να εκτελείται τοπικά. Για κάθε μοντέλο που χρησιμοποιείτε, αιτιολογείτε την επιλογή σε τέσσερις άξονες:

- **Ποιότητα στα ελληνικά,** μετρημένη στα δεδομένα του challenge, με σύγκριση τουλάχιστον δύο εναλλακτικών.
- **Άδεια χρήσης:** επιτρέπει εμπορική χρήση; Ελέγξτε το αρχείο άδειας του συγκεκριμένου repository, όχι της οικογένειας μοντέλων.
- **Προέλευση και ψηφιακή κυριαρχία:** ποιος το ανέπτυξε, πού, με ποια δεδομένα.
- **Κόστος εκτέλεσης:** μνήμη και χρόνος ανά επιχείρηση ή ανά profile στο laptop σας.

6. Κανόνες

- Κατά την εκτέλεση, η εφαρμογή δεν καλεί κανένα εξωτερικό AI API ή υπηρεσία AI.
- Εξωτερικές πηγές δεδομένων επιτρέπονται. Για κάθε πηγή δηλώνετε την προέλευση και την άδεια χρήσης της. Για το Google Places χρησιμοποιείτε δικό σας API key, εντός των δωρεάν μηνιαίων credits.
- Τα AI coding assistants επιτρέπονται στην ανάπτυξη. Δηλώνετε ποια εργαλεία χρησιμοποιήσατε και για ποιο σκοπό.
- Η λύση εκτελείται με μία εντολή σε καθαρό περιβάλλον, με οδηγίες εγκατάστασης.

7. Extra points

X1. **Γεωγραφικό ICP.** Profiles που βασίζονται στη θέση των μαγαζιών, από το στίγμα GPS.

X2. **Εμπλουτισμός ανά μαγαζί.** Σύνδεση των επιχειρήσεων με Google Places ή OpenStreetMap, με βάση την επωνυμία, τη διεύθυνση και το στίγμα. Αναφέρετε το ποσοστό των επιχειρήσεων που αντιστοιχίσατε και πώς χειριστήκατε τις αμφίβολες αντιστοιχίσεις.

X3. **Εφευρετικότητα.** Φέρτε όποια ανοιχτά δεδομένα πιστεύετε ότι κάνουν τα ICPs πιο έξυπνα, για παράδειγμα από το data.gov.gr. Επιβραβεύεται η διορατικότητα της ιδέας, όχι το πλήθος των πηγών.

8. Αξιολόγηση

8.1 Έλεγχος hold-out

Η ποιότητα των αποτελεσμάτων μετριέται αντικειμενικά:

1. Η ForceCRM έχει αφαιρέσει το 20% των πελατών από το πελατολόγιο πριν σας το δώσει.
2. Η εφαρμογή σας τρέχει στο πελατολόγιο που λάβατε και παράγει κατάταξη lookalike από το universe.
3. Μετριέται το Recall@k: το ποσοστό των κρυμμένων πελατών που εμφανίζονται στις πρώτες k θέσεις, για k = 500 και k = 2.000. Το lookalikes.csv περιέχει τουλάχιστον 2.000 προτάσεις συνολικά.
4. Το αποτέλεσμα συγκρίνεται με ένα απλό baseline: επιχειρήσεις με τον ίδιο κύριο ΚΑΔ με τους πελάτες, ταξινομημένες κατά συχνότητα του ΚΑΔ στο πελατολόγιο.

8.2 Κριτήρια

Κριτήριο	Τι εξετάζεται
Αρτιότητα λύσης	Η εφαρμογή λειτουργεί από την αρχή ως το τέλος, εκτελείται τοπικά, καλύπτει τις απαιτήσεις της ενότητας 4.
Επιλογή μοντέλου	Τεκμηρίωση στους τέσσερις άξονες της ενότητας 5.3, με μετρήσεις.
Αποτελέσματα	Recall@k στον έλεγχο hold-out και βελτίωση έναντι του baseline.
Κατανοητότητα	Μπορεί ένας πωλητής να καταλάβει και να εμπιστευτεί τα profiles και τις προτάσεις;
Υπεύθυνο AI	Σήμανση AI κειμένου, groundedness, model/data card, AI Act self-assessment.
Παρουσίαση	Σαφήνεια, demo, επιχειρηματική αξία.
Extra points	Τα στοιχεία της ενότητας 7.

9. EU AI Act σε μία σελίδα

- **Επίπεδο κινδύνου.** Η ομαδοποίηση επιχειρήσεων για B2B πωλήσεις δεν ανήκει στις κατηγορίες υψηλού κινδύνου του Παραρτήματος III.
- **Η παγίδα.** Η αξιολόγηση πιστοληπτικής ικανότητας φυσικών προσώπων είναι υψηλού κινδύνου. Οι ατομικές επιχειρήσεις είναι φυσικά πρόσωπα. Το σύστημά σας δεν παράγει βαθμολογία φερεγγυότητας.
- **Διαφάνεια (Άρθρο 50).** Ισχύει από τις 2 Αυγούστου 2026. Το περιεχόμενο που παράγει το AI σημαίνεται ως τέτοιο.
- **Χρονοδιάγραμμα.** Οι υποχρεώσεις για συστήματα υψηλού κινδύνου του Παραρτήματος III μετατέθηκαν στις 2 Δεκεμβρίου 2027 με τον Κανονισμό (ΕΕ) 2026/1744 (Digital Omnibus on AI).
- **AI literacy (Άρθρο 4).** Όσοι αναπτύσσουν και χρησιμοποιούν AI πρέπει να κατανοούν τι κάνει και πού αστοχεί.

Το self-assessment απαντά σε τέσσερις ερωτήσεις: Τι αποφασίζει ή προτείνει το σύστημα; Ποιος επηρεάζεται από αυτό; Τι βλέπει ο χρήστης για το πώς προέκυψε το αποτέλεσμα; Πού μπορεί να κάνει λάθος και πώς το εντοπίζουμε;

10. Παραδοτέα

- **Κώδικας** σε repository, με οδηγίες εγκατάστασης και εκτέλεσης με μία εντολή.
- **Web εφαρμογή** σε localhost, σύμφωνα με την απαίτηση Α8.
- **Αρχεία εξόδου** που εξάγει η εφαρμογή σε σταθερή μορφή, ώστε η αξιολόγηση να γίνεται αυτόματα:
  - `profiles.json` — profile_id, τίτλος, περιγραφή AI, πλήθος πελατών, μερίδιο τζίρου, σταθερότητα, εμπιστοσύνη, χαρακτηριστικά με lift και p-value
  - `assignments.csv` — company_id, profile_id, score
  - `lookalikes.csv` — profile_id, company_id, rank, score, αιτιολόγηση
- **Model & data card** (1–2 σελίδες): μοντέλα, αιτιολόγηση, δεδομένα και εξωτερικές πηγές με τις άδειές τους, περιορισμοί, γνωστά σφάλματα.
- **AI Act self-assessment** (1 σελίδα), σύμφωνα με την ενότητα 9.
- **Δήλωση χρήσης AI εργαλείων** στην ανάπτυξη.
- **Παρουσίαση** 5 λεπτών με live demo.